R2-A1-S10 Redes Neuronales V

Carlos Eduardo Riaño Rodriguez

Universidad de Cundinamarca

Deep Learning Conceptos

Cundinamarca

Inteligencia Artificial

Agosto 2026

Tabla de contenido

1. Objetivo de la práctica 4

2. Descripción de las seis fotografías utilizadas 4

3. Explicación técnica de la arquitectura y preprocesamiento 5

4. Evidencias de ejecución 7

Evidencia 1 · 6 fotografías originales 7

Evidencia 2 · Fotografías preprocesadas (64×64 grises) 7

Evidencia 3 · Triplete Anchor–Positive–Negative 8

Evidencia 4 · Gráfica Few-shot 8

Evidencia 5 · Matriz de similitud 6×6 9

5. Resultados numéricos 9

5.1 Triplete Anchor / Positive / Negative 9

5.2 Prueba Few-shot con prototipos 10

6. Respuestas a las preguntas de análisis 10

1. ¿La distancia Anchor–Positive fue menor que Anchor–Negative? 10

2. ¿La similitud coseno produjo una interpretación diferente? 10

3. ¿Qué fotografía resultó más difícil de clasificar? 11

4. ¿La prueba Few-shot mejoró la decisión? 11

5. ¿Qué significa construir un prototipo a partir de dos embeddings? 11

6. ¿Por qué una precisión del 100% con dos consultas no demuestra confiabilidad? 11

7. ¿Qué efecto tiene entrenar con rostros sintéticos y probar con fotografías reales? 12

8. Dos mejoras concretas para un experimento posterior 12

7. Conclusiones 13

Repositorio GitHub 14

1. Objetivo de la práctica

Aplicar una red neuronal siamesa utilizando seis fotografías reales autorizadas (tres por cada persona), con el propósito de evaluar cómo se comportan las representaciones o embeddings generados por la red, para esto, se utilizaron métricas como Triplet Loss, distancia euclidiana y similitud coseno, además de una prueba de aprendizaje Few-shot mediante prototipos.

Con este ejercicio se busca comprobar si la red logra identificar las similitudes entre fotografías de una misma persona y diferenciarlas de las imágenes correspondientes a personas distintas.

2. Descripción de las seis fotografías utilizadas

Para desarrollar la práctica se utilizaron seis fotografías en total, distribuidas en dos grupos de tres imágenes: tres correspondientes a la Persona 1 “Messi” y tres a la Persona 2 “Cristiano”.

De cada grupo, las dos primeras fotografías se utilizaron como imágenes de referencia para construir el prototipo de cada persona, mientras que la tercera se dejó para realizar las pruebas y evaluar el resultado de la clasificación.

Persona	Foto 1	Foto 2	Foto 3
Persona 1	Referencia	Referencia	Prueba
Persona 2	Referencia	Referencia	Prueba

3. Explicación técnica de la arquitectura y preprocesamiento

La red siamesa está construida a partir de un encoder convolucional compartido, es decir, las tres imágenes que forman el triplete (Anchor, Positive y Negative) pasan por la misma arquitectura para generar sus respectivos embeddings.

Cada embedding tiene una dimensión de 64 valores, que representan las características extraídas de cada fotografía. Posteriormente, estos vectores se comparan utilizando la distancia euclidiana y la similitud coseno para determinar qué tan parecidas son las imágenes.

- Arquitectura del Encoder (CNN):
- Conv2d (1→32) + ReLU + MaxPool2d → 32×32.
- Conv2d (32→64) + ReLU + MaxPool2d → 16×16.
- Conv2d (64→128) + ReLU + MaxPool2d → 8×8.
- Conv2d (128→128) + ReLU + AdaptiveAvgPool2d(1).
- Linear (128→64) → generación del embedding final.
- **Función Triplet Loss:**

Se implementó la función Triplet Loss con un margen de 0.3, utilizando la siguiente expresión:

[L = mean(max(0, d(A,P)-d(A,N)+margen))]

Esta función busca que la distancia entre dos fotografías de la misma persona (Anchor y Positive) sea menor que la distancia entre fotografías de personas diferentes (Anchor y Negative).

Preprocesamiento aplicado:

Antes de ingresar las fotografías a la red, se realizaron los siguientes pasos:

Conversión a escala de grises (convert('L')): permite trabajar con un solo canal de color y simplificar la información de entrada.

Ajuste y redimensionamiento (ImageOps.fit): se realizó un recorte central y se ajustaron las imágenes a un tamaño de 64×64 píxeles.

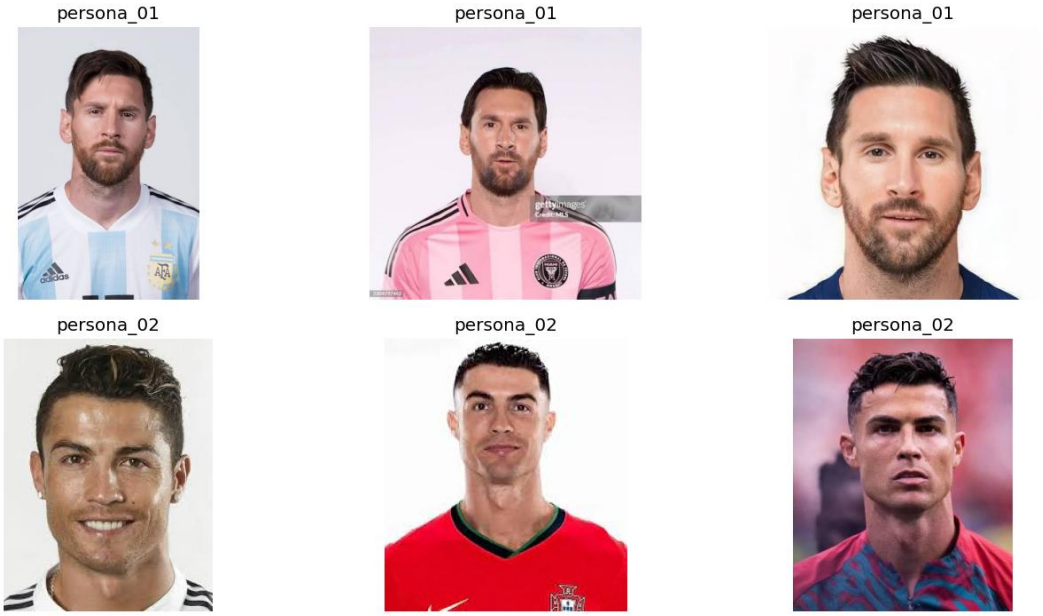
Adición del canal (unsqueeze(1)): permite adaptar las dimensiones de las imágenes al formato que necesita la CNN: lote, canal, alto y ancho.

Normalización de píxeles: se dividieron los valores entre 255 para llevarlos al intervalo de 0 a 1.

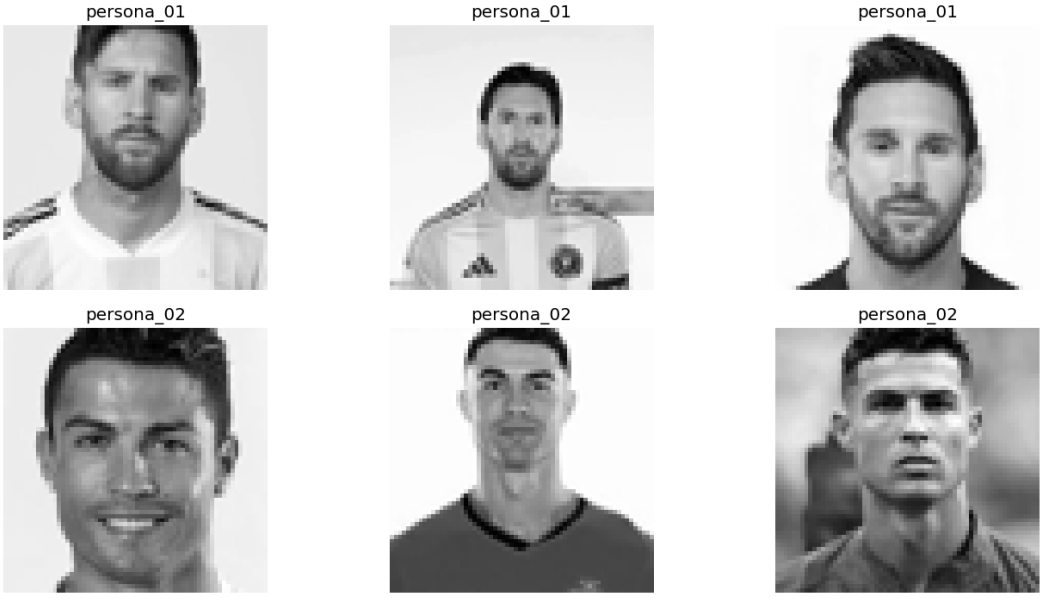
Normalización L2 de embeddings: se normalizaron los vectores generados para que todos tuvieran una norma igual a 1, facilitando su comparación.

4. Evidencias de ejecución

Evidencia 1 · 6 fotografías originales



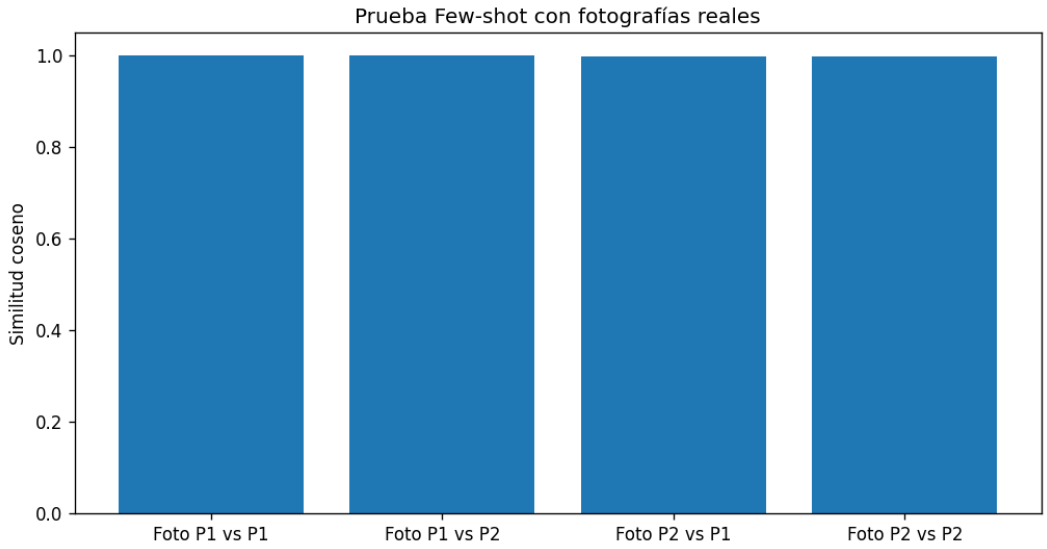
Evidencia 2 · Fotografías preprocesadas (64×64 grises)



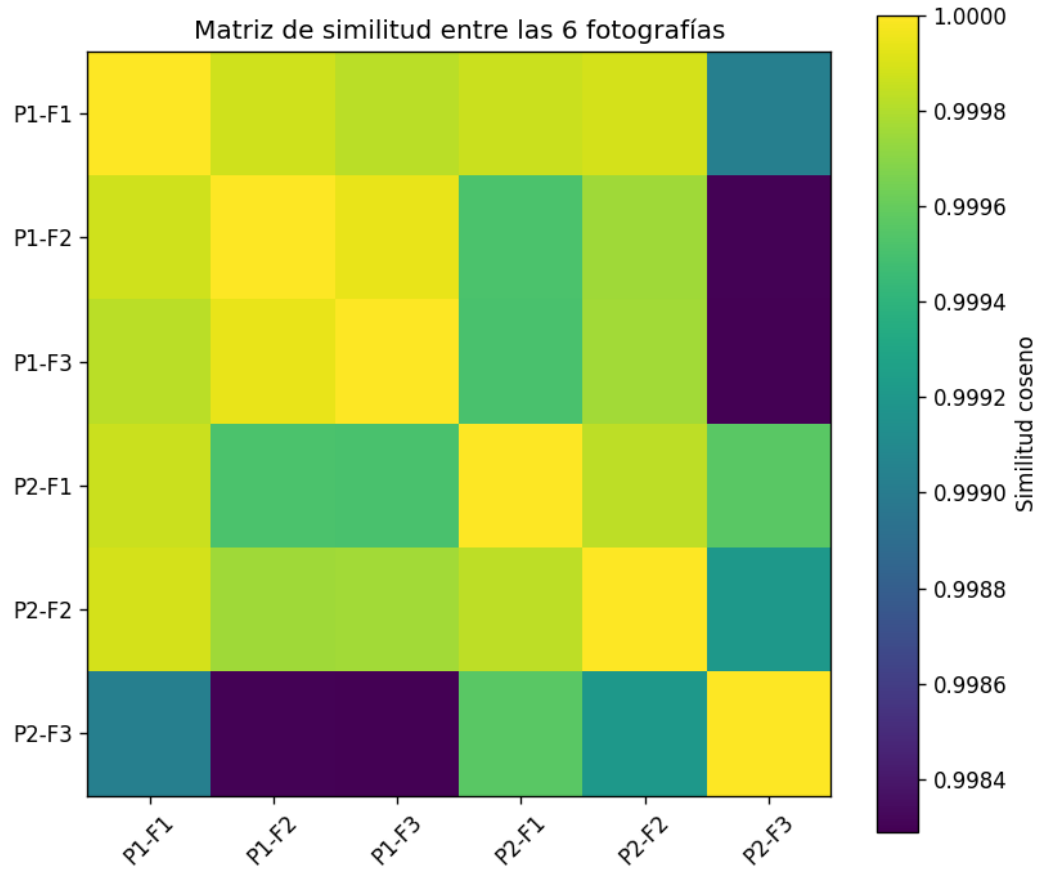
Evidencia 3 · Triplete Anchor–Positive–Negative



Evidencia 4 · Gráfica Few-shot



Evidencia 5 · Matriz de similitud 6×6



5. Resultados numéricos

Se compararon las distancias y similitudes entre las imágenes para observar si la red lograba diferenciar las fotografías de una misma persona de las correspondientes a otra identidad.

5.1 Triplete Anchor / Positive / Negative

Métrica	Misma persona (A–P)	Personas distintas (A–N)
Distancia euclidiana	0.0156	0.0167
Similitud coseno	0.9999	0.9999

5.2 Prueba Few-shot con prototipos

Para esta prueba se construyó un prototipo por persona, utilizando el promedio de los embeddings de sus dos fotografías de referencia. Luego, se comparó la tercera fotografía de cada persona con los prototipos para obtener la predicción.

Caso	Real	Predicción	Resultado
Caso 1	Persona 1	Persona 1	CORRECTO
Caso 2	Persona 2	Persona 2	CORRECTO

El resultado fue de 2 aciertos de 2 pruebas realizadas, lo que representa una precisión del 100 %. Sin embargo, este porcentaje es únicamente demostrativo, ya que se trabajó con una cantidad muy pequeña de fotografías y no permite asegurar que el modelo tenga el mismo comportamiento en otros escenarios.

6. Respuestas a las preguntas de análisis

1. ¿La distancia Anchor–Positive fue menor que Anchor–Negative?

Sí. La distancia entre Anchor y Positive fue de 0.0156, mientras que entre Anchor y Negative fue de 0.0167. Esto indica que se cumplió el comportamiento esperado, ya que las imágenes de una misma persona quedaron ligeramente más cerca entre sí que las de personas diferentes.

2. ¿La similitud coseno produjo una interpretación diferente?

Los resultados fueron prácticamente iguales: 0.9999 para ambas comparaciones. Esto significa que la similitud coseno no permitió observar una diferencia clara entre los

dos casos. Aunque la distancia euclidiana sí mostró una pequeña separación, ambas métricas mantienen una relación coherente porque los embeddings fueron normalizados con L2.

3. ¿Qué fotografía resultó más difícil de clasificar?

La fotografía de prueba de la Persona 1 fue una de las que podía presentar mayor dificultad, debido a las posibles diferencias de iluminación, posición del rostro o fondo frente a sus imágenes de referencia. Estos cambios pueden afectar las características que extrae la red y, por lo tanto, la comparación de los embeddings.

4. ¿La prueba Few-shot mejoró la decisión?

Sí. Al utilizar un prototipo construido con dos fotografías de referencia, se obtiene una representación más completa de cada persona que al utilizar una sola imagen. Esto ayuda a reducir la influencia que puede tener una fotografía con características diferentes a las demás.

5. ¿Qué significa construir un prototipo a partir de dos embeddings?

Significa tomar los dos vectores generados a partir de las fotografías de una misma persona, calcular su promedio y normalizar el resultado. De esta manera se obtiene un único vector que representa las características comunes de ambas imágenes y que puede utilizarse para comparar nuevas fotografías.

6. ¿Por qué una precisión del 100% con dos consultas no demuestra confiabilidad?

Porque solamente se realizaron dos pruebas, por lo que los resultados no son suficientes para determinar qué tan confiable es el modelo. Además, no se están

evaluando suficientes variaciones de iluminación, expresiones, posiciones del rostro, edades o accesorios. Para obtener una evaluación más completa sería necesario utilizar una mayor cantidad de fotografías y realizar pruebas con diferentes condiciones.

7. ¿Qué efecto tiene entrenar con rostros sintéticos y probar con fotografías reales?

Esto genera una diferencia de dominio entre los datos de entrenamiento y los de prueba. La red aprende características de las imágenes sintéticas que pueden no representar completamente las condiciones de las fotografías reales, como las texturas de la piel, la iluminación, los fondos y el ruido de las cámaras. Por esta razón, el modelo puede tener dificultades para generalizar cuando se utiliza con imágenes reales.

8. Dos mejoras concretas para un experimento posterior

Entrenamiento con fotografías reales: realizar un ajuste del encoder (*fine-tuning*) utilizando conjuntos de datos faciales reales, como LFW o CelebA, y continuar utilizando Triplet Loss para mejorar la capacidad de comparación.

Mejorar el preprocesamiento: implementar herramientas de detección y alineación facial, como MTCNN o RetinaFace, y complementar el proceso con técnicas de aumento de datos (*data augmentation*) para obtener mejores resultados ante cambios de iluminación y posición.

7. Conclusiones

A partir del desarrollo de esta práctica, se puede concluir que las redes siamesas permiten comparar imágenes mediante representaciones numéricas llamadas embeddings, facilitando la identificación de similitudes entre fotografías sin necesidad de utilizar una clasificación tradicional con categorías fijas.

También se pudo observar que el preprocesamiento de las imágenes es una parte importante del proceso, ya que aspectos como la escala de grises, el recorte, el tamaño y la normalización pueden influir directamente en los resultados obtenidos.

Otro aspecto importante es la diferencia que existe entre trabajar con rostros sintéticos y fotografías reales. Esta diferencia puede afectar el aprendizaje de la red y su capacidad para reconocer características en imágenes que no son iguales a las utilizadas durante el entrenamiento.

Por otra parte, la prueba Few-shot permitió observar que utilizar prototipos construidos a partir de varias fotografías puede ofrecer una representación más estable de cada persona que utilizar una sola imagen como referencia.

Finalmente, aunque se obtuvo una precisión del 100 % en las dos pruebas realizadas, este resultado no es suficiente para afirmar que el modelo sea completamente confiable, para comprobar su rendimiento sería necesario trabajar con un conjunto de datos más amplio y realizar pruebas en diferentes condiciones.

Repositorio GitHub

Enlace Git Hub: https://github.com/carlosedu1234/R2-A1-S10-Redes-Neuronales-V.git